커트라인 회귀 모델 결과 보고서

2026-10-07 · 청약 가점표 + 커트라인 회귀로 상/중/하 정확도 개선

당첨 가능성 상/중/하를 정하는 두 숫자를 모두 고쳤다. **사용자 점수**는 국토부 가점표로, **공고 기준 커트라인**은 회귀 모델로 바꿨다. 후보 3개 중 **그래디언트 부스팅**가 가장 정확했고, 처음 보는 2025~2026년 공고 1,023건에서 예전 방식보다 커트라인을 **평균 1.61점(11%) 덜 틀렸다.**

14.47 → 12.86	**-11%**	**66.3 → 70.2%**
커트라인 평균 오차(MAE, 점) 낮을수록 좋음	오차 감소율 베이스라인 대비	상/중/하 일치율 높을수록 좋음

1. 무엇을 바꿨나

[사용자 쪽] 무주택기간·부양가족·통장 → ① 국토부 가점표로 가점 계산 → 내 점수
[공고 쪽] 면적·분양가·세대수·과거 기록 → ② 회귀 모델로 커트라인 예측 → 예상 커트라인
③ 비교: 내 점수 ≥ 예상×1.1 상 / ≥ 예상×0.9 중 / 그 외 하

파일	바뀐 내용
services/eligibility_filter.py	가점을 국토부 가점표 구간대로 계산 (무주택 32 + 부양가족 35 + 통장 17 = 84점)
services/cutoff_model.py (새 파일)	학습 데이터 만들기, 후보 모델 3종 학습·평가, 저장, 공고별 커트라인 예측
scripts/train_cutoff_model.py (새 파일)	학습 실행 스크립트. 모델과 평가 결과(JSON)를 backend/models/에 저장
services/probability_estimator.py	기준 커트라인: 1순위 모델 예측값, 모델이 없거나 APT가 아니면 예전 3년 평균
api/routes/recommendations.py	(지역, 평형)별 캐시 제거. 모델은 공고마다 값이 달라서 공고별로 계산
tests/test_cutoff_model.py (새 파일)	누수 방지, 대체 동작, 상/중/하 규칙 등 9개 테스트
models/cutoff_reg.joblib (새 파일)	학습된 그래디언트 부스팅 모델

2. 데이터

항목	값
예측 대상	주택형별 **해당지역 최저 당첨가점(커트라인)** — historical_results.cutoff_score
전체 행	7,022행 (커트라인 평균 42.68점, 표준편차 19.61점)
학습용	2020~2024년 공고 5,999행
검증용	2025~2026년 공고 1,023행 — 학습에 쓰지 않고 채점에만 사용
출처	팀 DB 덤프(2026-10-02) 복원본. 청약홈 당첨가점 API + 공고 정보(listing_features)

학습/검증을 연도로 나눈 이유

앱은 **앞으로 나올 공고**를 예측한다. 그래서 무작위로 섞지 않고, 과거(2020~2024)로 배워서 그 뒤(2025~2026)를 맞히는지로 채점했다. 실제로 쓰는 상황과 같은 조건이다.

데이터 누수 막기

- **경쟁률·신청 건수는 쓰지 않았다.** 접수가 끝나야 알 수 있는 값이라, 쓰면 채점 점수만 좋아지고 실제로는 넣을 값이 없다.
- **과거 기록 특징은 그 공고 연도 '이전' 3년치만** 쓴다. 예: 2025년 공고 → 2022~2024년 평균. 같은 해 결과(자기 자신 포함)는 넣지 않는다. 테스트 test_history_uses_only_previous_three_years로 확인했다.

3. 사용한 모델

모델	어떻게 예측하나	고른 이유
베이스라인 (예전 방식)	같은 지역+평형의 직전 3년 커트라인 평균. 없으면 같은 지역 평균	새 모델이 반드시 이겨야 하는 기준
Ridge 선형회귀	특징마다 가중치를 곱해 더한다. 지역은 원-핫, 빈 값은 중앙값	가장 단순하고 해석하기 쉬움
랜덤포레스트	나무 300그루를 각각 학습해 평균	비선형 관계, 튜닝 없이도 무난
그래디언트 부스팅 (HistGradientBoosting)	앞 나무가 틀린 만큼을 다음 나무가 고쳐 나간다. 빈 값·지역(범주형)을 직접 처리, MAE를 줄이도록 학습	표 형태 데이터에서 보통 가장 강함

특징 (공고 접수 전에 알 수 있는 값만)

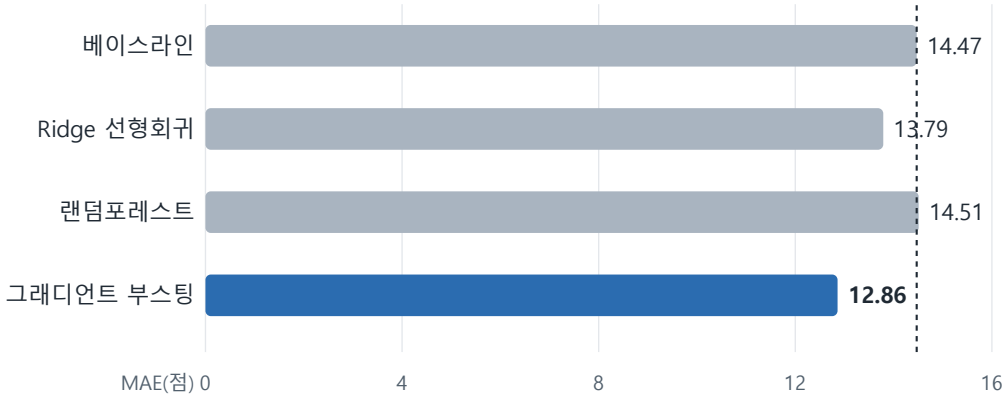
구분	특징
공고 정보	지역, 전용면적, 분양가, ㎡당 분양가, 일반공급 세대수, 공급 세대수, 공고 연도
규제	민영 여부, 투기과열지구, 조정대상지역, 분양가상한제, 공공택지
과거 기록	직전 3년 커트라인 평균 — 같은 지역 / 같은 지역+평형 / 같은 시군구, 평균에 쓴 표본 수

4. 결과

검증용 1,023건(2025~2026년)으로 채점했다. 베이스라인도 모든 검증 공고에 값을 냈기 때문에 같은 공고로 비교했다.

방법	MAE (점) ↓	RMSE (점) ↓	R^2 ↑	상/중/하 일치율 ↑
베이스라인 (직전 3년 평균)	14.47	18.36	0.335	66.3%
Ridge 선형회귀	13.79	17.40	0.403	67.9%
랜덤포레스트	14.51	18.33	0.337	65.8%
그래디언트 부스팅 ★	**12.86**	**17.51**	**0.396**	**70.2%**

커트라인 평균 오차(MAE) 비교 — 짧을수록 좋다. 점선은 베이스라인



결과 읽는 법

- **MAE**: 커트라인을 평균 몇 점 틀렸나. 그래디언트 부스팅는 12.86점, 베이스라인은 14.47점 → **1.61점 덜 틀림**.
- **RMSE**: 크게 틀린 경우에 벌점을 더 주는 오차. 부스팅이 MAE를 줄이도록 학습해서 RMSE는 Ridge와 비슷하다.
- **R²**: 커트라인 차이를 얼마나 설명하나(1이 완벽). 0.335 → 0.396.
- **상/중/하 일치율**: 가상의 사용자 점수 20~70점마다, 실제 커트라인으로 낸 상/중/하와 예측으로 낸 상/중/하가 같은 비율. 66.3% → 70.2% (**+3.9%p**). 사용자 화면에 직접 보이는 지표다.
- **랜덤포레스트**는 베이스라인과 거의 같아 개선이 없었다. 그래서 '모델을 쓰면 무조건 좋아진다'가 아니라 비교가 꼭 필요하다.

연도별로 봐도 매년 개선됐다

검증 연도	공고 수	베이스라인 MAE	그래디언트 부스팅 MAE	개선
2025	534	15.21	13.37	-1.84점
2026	489	13.66	12.31	-1.35점

어떤 특징이 중요했나 (순열 중요도)

특징 하나의 값을 무작위로 섞었을 때 MAE가 얼마나 나빠지는지. 많이 나빠질수록 모델이 그 특징에 의존한다.

순위	특징	섞었을 때 MAE 증가
1	지역	+3.08점
2	같은 시군구 직전 3년 평균	+1.73점
3	분양가	+0.75점
4	㎡당 분양가	+0.64점
5	일반공급 세대수	+0.43점
6	전용면적	+0.30점
7	같은 지역+평형 직전 3년 평균 (예전 기준값)	+0.16점

순위	특징	섞었을 때 MAE 증가
8	공급 세대수	+0.15점

지역과 **시군구 단위 과거 기록**이 가장 중요했고, 그다음이 **분양가**였다. 예전 방식은 시도 단위 평균만 봤는데, 더 좁은 동네 기록과 가격을 함께 본 것이 개선의 주된 이유다.

5. 실제 공고 예시 (2026년 8월 이후 공고)

같은 지역·같은 평형이면 예전 방식은 모두 같은 기준값이었다. 모델은 공고마다 다른 값을 낸다. (아직 당첨 결과가 없는 공고라 어느 쪽이 맞았는지는 결과 발표 후 확인할 수 있다.)

공고 (지역 시군구)	전용면적	분양가	예전 기준	모델 예측
인천계양 A17블록 신혼희망타운(공공분양)(본청 (인천 계양구)	55.9㎡	5.08억	33.3점	**46.8점**
시흥하중지구 A-4블록 신혼희망타운(공공분양) (경기 시흥시)	55.0㎡	3.67억	27.0점	**22.3점**
시흥하중지구 A-4블록 신혼희망타운(공공분양) (경기 시흥시)	56.0㎡	3.94억	27.0점	**24.6점**
광명 시티프라디움 에듀하임 (경기 광명시)	85.0㎡	11.98억	35.0점	**28.3점**
에코델타시티 금강펜테리움 에코리버 (부산 강서구)	60.0㎡	5.32억	41.8점	**40.9점**

예: 가점 35점인 사용자는 인천계양 공고에서 예전 기준(33.3점)으로는 **중**이었지만 모델 기준(46.8점, ×0.9 = 42.1점)으로는 **하**다. 반대로 광명 85㎡형은 기준이 35.0점 → 28.3점(×1.1 = 31.1점)이 되어 **중 → 상**이 된다.

6. 가점표 변경 결과

예: 무주택 3년, 부양가족 0명, 통장 3년	무주택	부양가족	통장	합계
예전 임시식	6	0	6	12점
국토부 가점표 (현재)	8	5	5	**18점**

- 회귀 모델이 배우는 커트라인은 청약홈이 **공식 가점표로 계산한 실제 당첨자 점수**다. 사용자 점수도 같은 가점표로 계산해야 두 숫자를 비교할 수 있다.
- 구간 경계값(11개월→2점, 12개월→4점 등)을 테스트 5개로 확인했다.

7. 한계와 다음 단계

> **아직 오차가 크다.** 개선됐지만 평균 12.9점 틀린다(커트라인 표준편차 19.61점). 청약은 1~2점 차이로 당락이 갈리므로 상/중/하는 '참고용 위치'로 보여주고 단정하지 않는다 (REQ-04: '당첨 확률'이라고 쓰지 않는다).

- **공공분양에도 적용된다.** 학습 데이터는 청약홈 APT 가점 결과인데, 신혼희망타운 같은 공공분양은 가점제가 아닌 경우가 많다. 공급유형별로 적용 범위를 나누는 것이 다음 개선 후보다.
- **데이터 시점**: 2026-10-02 덤프 기준. 수집이 쌓이면 python -m scripts.train_cutoff_model로 다시 학습한다.
- **속도**: 공고 1건당 약 0.04초. 희망 지역 공고가 수백 건이면 추천 응답이 몇 초 걸릴 수 있다. 필요하면 예측값을 미리 계산해 저장한다.
- **상/중/하 경계(×1.1, ×0.9)**는 예전 그대로다. 예측 오차를 반영해 경계를 다시 정하는 것도 개선 후보다.
- **가점표**: 만 30세 미만 미혼의 무주택기간 0점 규칙은 프로필에 나이·혼인 여부가 없어 아직 반영하지 못했다.

다시 실행하는 방법

```
cd backend
python -m scripts.train_cutoff_model      # 학습 + 평가 → models/cutoff_reg.joblib, cutoff_reg_metrics.json
python -m pytest tests/test_cutoff_model.py tests/test_eligibility_filter.py
```